

clinic_merge 資料庫架構文件

更新日期：2026-06-23

專案位置：/Users/thousand0001/PycharmProjects/clinic_merge

1. 架構定位

本專案目前有兩條流程：

1. 傳統 Excel 直產流程

各診所 前置清洗_*.py → 選會員_共用核心_*.py → 正式 Excel。

2. 資料庫旁路流程

db_pipeline parser → DatasetBundle → PostgreSQL staging → 從 DB 取回 → 正式 Excel。

資料庫旁路的目標是把各系統來源資料標準化後，寫入 PostgreSQL staging，保留來源檔、sheet、列號與 row hash，讓後續可以重產、稽核與追溯。

2. 主要模組

```
db_pipeline/
├── cli/
│   ├── inventory.py # 只讀盤點來源資料夾
│   ├── parse.py    # 解析來源資料，不寫 DB
│   ├── stage.py    # parse → validate → stage 寫入 DB
│   ├── batches.py  # 查詢批次
│   └── output.py   # 從 DB batch 產出 Excel
├── parsers/        # 各來源系統 parser
├── datasets/        # 標準資料模型 DatasetBundle
├── validation/      # 資料驗證
├── storage/         # PostgreSQL staging 寫入
├── providers/       # 從資料夾或 PostgreSQL 讀回 DatasetBundle
└── output/         # DatasetBundle → 會員資料 dict
```

3. 資料流

```
來源資料夾
↓
Parser：耀聖 / 新耀聖 / 展望 / 醫聖 / 調和 / 宏誠 / 方鼎 / 杏翔...
↓
DatasetBundle
↓
ValidationReport
↓
PostgresStagingWriter
↓
PostgreSQL staging tables
↓
PostgresDataProvider
↓
DatasetBundle
```

↓
member_builder.build_from_bundle()
↓
資料庫輸出0601.py / 舊輸出器
↓
正式 Excel

4. DB 連線設定

目前程式使用 psql subprocess，不依賴 psycopg2。

環境變數：

```
CLINIC_PSQL      # psql 路徑，可選
CLINIC_DB_HOST   # 預設 localhost
CLINIC_DB_PORT   # 預設 5432
CLINIC_DB_USER   # 預設 thousand0001
CLINIC_DB_NAME   # 預設 clinic_merge
CLINIC_DB_PASSWORD # 密碼，寫入 PGPASSWORD
```

目前本機測試狀態：localhost:5432 連線被拒絕，代表 PostgreSQL 沒啟動或未開 TCP 連線。

5. 標準資料模型 DatasetBundle

來源檔經 parser 後會轉成 DatasetBundle。

主要資料集：

```
members          # 照護名單 / 家醫會員
monthly_claims    # 門診次數費用
p4p_cases         # P4P 收案
p4p_tracks        # P4P 追蹤
lab_results       # 檢驗資料
screenings        # 預防保健 / 篩檢資料
member_selections # 自選 / 不選 / 指定名單旗標
raw_source_files  # 來源檔追蹤
raw_source_rows   # 原始列追蹤
```

每筆標準資料都有 SourceTrace：

```
clinic_code
batch_id
source_system
source_file
source_sheet
source_row
raw_row_hash
```

這是資料庫流程的追溯核心。

6. staging_v1 草案 schema

檔案位置：

```
db_pipeline/storage/schema/001_staging_v1.sql
```

目前 README 註記：這是旁路 staging schema 草案，尚未確認已在正式 PostgreSQL 執行。

staging_v1.members

會員基本資料與疾病欄位。

主欄位：

batch_id
clinic_id
clinic_code
source_system
person_id
name
birth_date
sex
phone
mobile
address
case_category
quality_roster
multi_chronic_65
high_visit
chronic_mark
non_chronic_mark
same_clinic_previous_year
disease_pattern
ascvd
three_highs
hypertension
hyperlipidemia
hyperglycemia
source_file
source_sheet
source_row
raw_row_hash
staged_at

唯一鍵：

batch_id, source_file, source_sheet, source_row, person_id

staging_v1.monthly_claims

門診次數與費用。

主欄位：

batch_id
clinic_id
clinic_code
source_system
person_id
roc_year # 114 或 115
month # 1~12
visit_count
amount
last_visit_date
source_file

source_sheet
source_row
raw_row_hash
staged_at

唯一鍵：

batch_id, source_file, source_sheet, source_row, person_id, roc_year, month

staging_v1.p4p_cases

P4P 收案資料。

person_id
plan
status
enrolled_at
source trace...

staging_v1.p4p_tracks

P4P 追蹤資料。

person_id
plan
last_tracked_at
next_track_at
overdue
source trace...

staging_v1.lab_results

檢驗資料。

person_id
test_code
result_value
tested_at
source trace...

目前輸出端支援：

HbA1c
LDL
UACR

staging_v1.screenings

預防保健 / 篩檢資料。

person_id
screening_type
screened_at
source trace...

目前輸出端支援：

成人健檢
子宮抹片
老人流感
糞便潛血
肝炎篩檢

staging_v1.member_selections

會員選取旗標。

person_id
selection_type
source_trace...

允許值：

designated_114
self_selected_115
excluded_115

staging_v1.validation_issues

驗證問題紀錄。

severity # error / warning / info
dataset_name
issue_code
message
source_file
source_sheet
source_row
created_at

7. meta.batch_source_files

檔案位置：

db_pipeline/storage/schema/002_batch_source_files.sql

用途：記錄每個批次引用哪些來源檔案。

meta.batch_source_files
├── batch_id
└── source_file_id

主鍵：

batch_id, source_file_id

用途說明：

- meta.source_files.batch_id 只代表首次引入批次。
- meta.batch_source_files 才能表示每個 batch 實際引用了哪些來源檔。

8. 現況重要差異

目前有一個需要注意的架構落差：

001_staging_v1.sql 建立的是：

```
staging_v1.members
staging_v1.monthly_claims
staging_v1.p4p_cases
staging_v1.p4p_tracks
staging_v1.lab_results
staging_v1.screenings
staging_v1.member_selections
```

但目前 db_pipeline/storage/__init__.py 實際寫入的是：

```
staging.members
staging.claims
staging.member_flags
staging.p4p_records
staging.screenings
staging.lab_results
```

而 PostgresDataProvider 讀回時也使用：

```
staging.members
staging.claims
staging.member_flags
staging.p4p_records
staging.screenings
staging.lab_results
```

也就是說：

```
schema 草案：staging_v1.*
目前程式：staging.*
```

這兩者尚未完全對齊。若要正式整理 DB 流程，這是第一個需要決定的架構點：

1. 將程式改成使用 staging_v1.*
2. 或補正式 staging.* schema 文件
3. 或建立 view / alias 讓兩者相容

9. parser 支援現況

目前 parser registry 支援：

```
sm          # 耀聖
new_sm      # 新耀聖
prospect    # 展望
medical_saint # 醫聖
tiaohe      # 調和
hongcheng   # 宏誠
custom      # 自行系統
fangding    # 方鼎
xingxiang   # 杏翔
```

近期檢查發現：

- 耀聖 DB parser 目前尚未解析 預防保健.CSV

- 所以耀聖若走 DB 流程，screenings 會是 0
- 但 DB 後段與輸出端本身已支援五項預防保健欄位

10. 輸出欄位對應

db_pipeline/output/member_builder.py 會把 DatasetBundle 轉成舊輸出器可用的 member dict。

門診次數費用

```
114_count_q1  # 114 年前 4 個月次數
114_count    # 114 年全年次數
114_amount   # 114 年費用總額
115_count    # 115 年次數
115_amount   # 115 年費用總額
114_avg_amount # 114 年月平均費用
115_avg_amount # 115 年月平均費用
last_visit   # 最後就診日
```

名單旗標

```
designated_114 → designated / is_114_member
self_selected_115 → self_select
excluded_115x → exclude_select
```

注意：目前 member_builder 接受 excluded_115x，但 staging_v1.member_selections 草案允許值是 excluded_115，命名也需要統一。

檢驗

```
HbA1c → hba1c / hba1c_date
LDL → ldl / ldl_date
UACR → uacr / uacr_date
```

篩檢

```
成人健檢 → adult
子宮抹片 → pap
老人流感 → flu
糞便潛血 → fit
肝炎篩檢 → bc
```

11. 建議下一步

若要讓資料庫流程穩定正式化，建議依序處理：

1. 決定正式 schema 名稱：staging 或 staging_v1
2. 對齊 schema 欄位與程式欄位名稱
3. 統一 member_selection 的旗標命名
4. 補耀聖 預防保健.CSV → ScreeningRecord
5. 補新式 / 舊式外來人口統一證號 ID 規則

6. 補電話正規化規則
7. 建立資料庫 migration 執行文件
8. 建立最小驗證 SQL :
 - 批次筆數
 - 會員筆數
 - claims L/M/N/O 加總
 - screenings 五項命中數
 - E1/E2/E1/E2 重疊數

12. 目前檢查限制

本文件依據專案內現有程式與 SQL schema 檔整理。

本機 PostgreSQL 目前無法連線，因此尚未核對實體資料庫內實際 schema。